

Trabajo Práctico: Metodos Estadísticos Aplicados al Seguro

Alumnos: Malena Irisarri, Román Landa



Rosario, Argentina

10 de Mayo de 2025

Introducción

En el sector asegurador, garantizar la solvencia financiera es fundamental para cumplir con las obligaciones frente a los asegurados y mantener la estabilidad de la compañía. En este contexto, el Margen de Solvencia Mínimo (MSM) emerge como un indicador clave que asegura la capacidad de la aseguradora para afrontar siniestros inesperados, incluso en escenarios adversos.

Para este trabajo, se analizará la sub-cartera de pólizas de seguros automotores de una compañía, compuesta por 25.615 pólizas, con el objetivo de determinar el MSM que permita alcanzar una Probabilidad de Solvencia del 99% durante el año 2024. El análisis se basará en datos históricos de siniestros de los años 2021, 2022 y 2023, considerando ajustes por inflación mediante la serie CER publicado en Banco Central de la República Argentina (BCRA). Adicionalmente, se explorarán diferentes distribuciones de probabilidad, para modelar el comportamiento de los siniestros y calcular los recargos de seguridad necesarios sobre las primas puras.

Este informe presentará alternativas para el cálculo del MSM bajo es importante spuesto de que **durante el año 2024 se va a mantener la cantidad de pólizas y el perfil de las mismas**. El objetivo final es asegurando la estabilidad financiera y cumpliendo con los requisitos regulatorios de la Superintendencia de Seguros de la Nación (SSN).

Datos

Contamos con una base de datos que contiene 3431 cuantías pagadas durante el año 2023. A ella le aplicamos la actualización por CER llevando todos los valores al día 01-01-2024.

```
cuantias_23 <- read_excel("Trabajo Final 2024 Base de Datos .xlsx",
                          col_types = c("date", "numeric"))
cer23 <- read_excel("cer23.xlsx",
                   col_types = c("date", "numeric"))

cuantias_23 <- cuantias_23 %>%
  left_join(cer23, by = "Fecha")

cuantias_23 <- cuantias_23 %>%
  mutate(cuantia24 = `Cuantia` * (cer23$ValorCER[366]/ValorCER))

head(cuantias_23, 10)%>%
  kbl(caption = "Cuantias Pagadas en 2023", align = "c") %>% # Añadir un título
  kable_styling(bootstrap_options = "striped", full_width = FALSE) %>%
  row_spec(0, background = "#66CDAA")
```

Análisis Descriptivo

Realizamos un breve análisis descriptivo para observar cual fué la frecuencia y la severidad durante 2023


```
##### DESCRIPTIVO #####
# Crear columna con el mes en formato año-mes

cuantias_23 <- cuantias_23 %>%
  mutate(mes = format(as.Date(Fecha), "%Y-%m"))
```

Table 1: Cuantías Pagadas en 2023

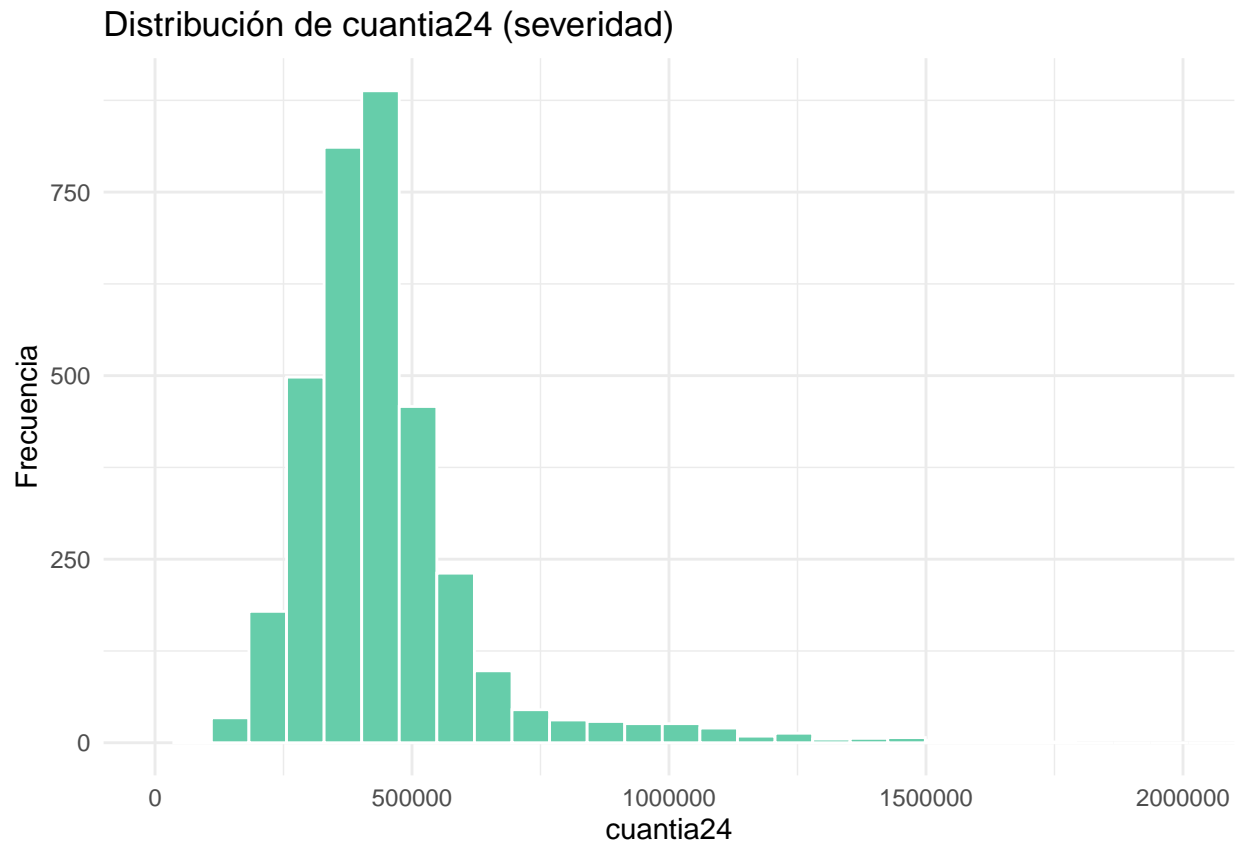
Fecha	Cuántia	ValorCER	cuántia24
2023-01-02	70939	73.7253	178636.7
2023-01-02	107871	73.7253	271637.9
2023-01-02	148775	73.7253	374641.3
2023-01-02	167011	73.7253	420562.7
2023-01-02	180152	73.7253	453654.0
2023-01-02	220063	73.7253	554156.8
2023-01-02	248064	73.7253	624668.2
2023-01-02	269251	73.7253	678020.7
2023-01-03	78566	73.8392	197537.6
2023-01-03	79646	73.8392	200253.1

```
ggplot(cuantias_23, aes(x = mes)) +
  geom_bar(fill = "#66CDAA") +
  labs(title = "Cantidad de cuantías pagadas por mes (frecuencia)",
       x = "Mes",
       y = "Cantidad de pagos") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



```
#####
```

```
ggplot(cuantias_23, aes(x = cuantia24)) +  
  geom_histogram(fill = "#66CDAA", bins = 60, color = "white") +  
  labs(title = "Distribución de cuantia24 (severidad)",  
       x = "cuantia24",  
       y = "Frecuencia") +  
  theme_minimal() +  
  coord_cartesian(xlim = c(0, 2000000))
```



En estos gráficos podemos observar que la frecuencia parece constante a lo largo del periodo de análisis y que la severidad parece distribuirse de forma asimétrica con muchos siniestros pequeños y algunos pocos de gran importe. Además, podemos ver que al menos el 50% de los siniestros le costaron menos de 417.603,40.- pesos a la compañía y que el costo medio de los mismos fue de 454.566,30.- pesos con un desvío estándar de 233.500,60.-

Simulaciones

Para predecir el monto esperado de siniestros y calcular el margen de solvencia, simularemos la frecuencia (número de siniestros) y la severidad (monto por siniestro), probando distintas combinaciones de distribuciones.

Comenzamos analizando cuál distribución se ajusta mejor a nuestros datos observados. El siguiente gráfico compara los datos reales con las distribuciones candidatas (Lognormal, Weibull, Pareto y Burr) para la severidad:

```

datos <- na.omit(cuantias_23$cuantia24)

# Ajustes
ajuste_lnorm <- fitdist(datos, "lnorm")
ajuste_weibull <- fitdist(datos, "weibull")
ajuste_burr <- fitdist(datos, "burr", start = list(shape1 = 2, shape2 = 2, rate = 2))
ajuste_pareto <- fitdist(datos, "pareto", start = list(shape = 2, scale = min(datos)))

ggplot(data.frame(x = datos), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 50, fill = "#66CDAA", color = "black", alpha = 0.5)

# --- Todas las líneas en tipo "solid" (continua) y tamaño 0.7 (más fino) ---
stat_function(fun = dlnorm,
  args = list(meanlog = ajuste_lnorm$estimate["meanlog"],
    sdlog = ajuste_lnorm$estimate["sdlog"]),
  aes(color = "Log-normal", linetype = "Log-normal"),
  size = 0.7) + # Más fina
stat_function(fun = dweibull,
  args = list(shape = ajuste_weibull$estimate["shape"],
    scale = ajuste_weibull$estimate["scale"]),
  aes(color = "Weibull", linetype = "Weibull"),
  size = 0.7) + # Más fina
stat_function(fun = dburr,
  args = list(shape1 = ajuste_burr$estimate["shape1"],
    shape2 = ajuste_burr$estimate["shape2"],
    rate = ajuste_burr$estimate["rate"]),
  aes(color = "Burr", linetype = "Burr"),
  size = 0.7) + # Más fina
stat_function(fun = dpareto,
  args = list(shape = ajuste_pareto$estimate["shape"],
    scale = ajuste_pareto$estimate["scale"]),
  aes(color = "Pareto", linetype = "Pareto"),
  size = 0.7) + # Más fina

# --- Personalización de colores y tipos de línea en la leyenda ---
scale_color_manual(name = "Distribución",
  values = c("Log-normal" = "darkblue",
    "Weibull" = "#5F9EA0",
    "Burr" = "#8B0A50",
    "Pareto" = "#CD5555")) +
scale_linetype_manual(name = "Distribución",
  values = c("Log-normal" = "solid", # Todas "solid"
    "Weibull" = "solid",
    "Burr" = "solid",
    "Pareto" = "solid")) +

# --- Formato del Eje X ---
scale_x_continuous(labels = scales::number_format(big.mark = ".", decimal.mark = ",", accuracy = 1)) +
labs(title = "Ajuste de distribuciones a las cuantias",
  x = "Valor de las Cuantias",
  y = "Densidad") +
theme_minimal() +


```

```

theme(legend.position = "right",
      legend.title = element_text(face = "bold"),
      legend.text = element_text(size = 10),
      axis.title.y = element_blank(), # Elimina el título del eje Y
      axis.text.y = element_blank(), # Elimina los números/etiquetas del eje Y
      axis.ticks.y = element_blank(), # Elimina las marcas del eje Y
      axis.line.y = element_blank() # Elimina la línea del eje Y
)+
coord_cartesian(xlim = c(0, 2500000))

```

Ajuste de distribuciones a las cuantías



Optamos por una distribución Binomial Negativa para la frecuencia de siniestros por ser el caso más general para representar lo observado, ya que esta cubre los casos donde la varianza supera a la esperanza, situación frecuente en seguros de automóviles.

Para las cuantías individuales de los siniestros, seleccionamos dos distribuciones de cola pesada que muestran el mejor ajuste a nuestros datos: la Log-Normal, que modela adecuadamente la asimetría positiva y la Burr que capturar diversos patrones de severidad, incluyendo eventos extremos.

Continuamos simulando 10.000 años para las combinaciones de distribuciones.

```

# Cant siniestros
## Binomial negativa
# Datos históricos
polizas <- c(24752, 25348, 25615)
siniestros <- c(3023, 3581, 3431)

tasas <- siniestros / polizas # Tasa siniestral por año

```

```

tasa_prom <- mean(tasas) # Media de la tasa siniestral
polizas_2024 <- 25615 # Simulación para 25615 pólizas
mu <- tasa_prom * polizas_2024
var_siniestros <- var(siniestros)
size <- mu^2 / (var_siniestros - mu)

# Simular 1000 observaciones de siniestros
set.seed(1511) # Cantidad de años a simular

# Cantidad de años a simular
n_sim <- 10000

# Vectores para guardar resultados
suma_burr <- numeric(n_sim)
suma_lnorm <- numeric(n_sim)

# Simulación año por año
for (i in 1:n_sim) {
  # Simular cantidad de siniestros
  cantidad <- rbinom(1, mu = mu, size = size)

  # Simular severidades y sumar
  if (cantidad > 0) {
    burr_vals <- rburr(cantidad,
                      shape1 = ajuste_burr$estimate["shape1"],
                      shape2 = ajuste_burr$estimate["shape2"],
                      rate = ajuste_burr$estimate["rate"])

    lnorm_vals <- rlnorm(cantidad,
                       meanlog = ajuste_lnorm$estimate["meanlog"],
                       sdlog = ajuste_lnorm$estimate["sdlog"])

    suma_burr[i] <- sum(burr_vals)
    suma_lnorm[i] <- sum(lnorm_vals)
  } else {
    suma_burr[i] <- 0
    suma_lnorm[i] <- 0
  }
}

# Resultado final como data.frame
resultados <- data.frame(lognormal = suma_lnorm,
                        burr = suma_burr)

```

```

media <- mean(resultados$lognormal)
desvio <- sd(resultados$lognormal)
coef_asimetria <- skewness(resultados$lognormal)

z_99 <- qnorm(0.99, 0, 1)
y_99 <- z_99 + coef_asimetria/6 * (z_99^2-1)

y <- y_99* desvio + media

```

```

MSM_1porc <- y-(media*1.01)
MSM_1.5porc <- y-(media*1.015)
MSM_2porc <- y-(media*1.02)
MSM_log <- c(MSM_1porc, MSM_1.5porc, MSM_2porc)

media_burr <- mean(resultados$burr)
desvio_burr <- sd(resultados$burr)
coef_asimetria_burr <- skewness(resultados$burr)

z_99 <- qnorm(0.99, 0, 1)
y_99 <- z_99 + coef_asimetria_burr/6 * (z_99^2-1)

y <- y_99* desvio_burr + media_burr

MSM_1porc_burr <- y-(media_burr*1.01)
MSM_1.5porc_burr <- y-(media_burr*1.015)
MSM_2porc_burr <- y-(media_burr*1.02)
MSM_burr <- c(MSM_1porc_burr, MSM_1.5porc_burr, MSM_2porc_burr)

```

Resultados

A continuación presentamos los márgenes de solvencia mínimos obtenidos mediante simulación para diferentes porcentajes de recargo de seguridad, comparando los resultados bajo los dos modelos de severidad considerados: Log-Normal y Burr. La tabla resume los valores requeridos para garantizar un 99% de probabilidad de solvencia, mostrando cómo varían las necesidades de capital según el porcentaje de recargo aplicado y la distribución utilizada.

Los montos están expresados en pesos argentinos y representan el capital adicional que la compañía debería mantener para cubrir posibles desviaciones adversas en su cartera de seguros automotores durante el año 2024.

```

library(kableExtra)
library(knitr)
porc <- c("1%", "1,5%", "2%")
tabla1 <- data.frame(porc, MSM_log, MSM_burr)
colnames(tabla1) <- c("Porcentaje de Recargo de Seguridad", "Margen de Solvencia Mínimo Log-Normal", "Ma

tabla1$`Margen de Solvencia Mínimo Log-Normal` <-
  paste0("$", formatC(tabla1$`Margen de Solvencia Mínimo Log-Normal`,
    big.mark = ".", format = "f", digits = 0))

tabla1$`Margen de Solvencia Mínimo Burr` <-
  paste0("$", formatC(tabla1$`Margen de Solvencia Mínimo Burr`,
    big.mark = ".", format = "f", digits = 0))

tabla1 %>%
  kbl(caption = "Tabla de Margen de Solvencia Mínimo según Porcentaje de Recargo se Seguridad", align =
  kable_styling(bootstrap_options = "striped", full_width = FALSE) %>%
  row_spec(0, background = "#66CDAA")

```


Table 2: Tabla de Margen de Solvencia Mínimo según Porcentaje de Recargo se Seguridad

Porcentaje de Recargo de Seguridad	Margen de Solvencia Mínimo Log-Normal	Margen de Solvencia Mínimo Burr
1%	\$302.082.238	\$299.790.852
1,5%	\$294.441.320	\$292.231.306
2%	\$286.800.402	\$284.671.759